Laboratório 04 — Testes de Hipótese por Dentro

LAB04 — Laboratório 04 · 20 pontos

Curso Engenharia de Software	Disciplina Laboratório de Experimentação de Software
Turno Noite	Período / Sala 6º
Professor(a) Danilo Maia	

Testes de hipótese por dentro: cenário, simulação e visualização

1. Objetivo

Entender **como um teste de hipótese funciona** e **quando escolher um teste em vez de outro**, usando simulação e gráficos.

O grupo vai criar um cenário de Engenharia de Software, escolher **dois testes** que poderiam responder à mesma pergunta e comparar os dois. Como é o próprio grupo que gera os dados da simulação, ele sabe a resposta certa e pode verificar quantas vezes cada teste acerta ou erra. Uma pequena amostra de **dados reais** serve para deixar a simulação realista e para testar, no fim, se a recomendação do grupo se sustenta.

Este laboratório é independente dos anteriores: não usa dados nem resultados de outros laboratórios.

> Material de apoio: guia *Testes de Hipótese em Experimentação de Software* (Testes 1 a 11, com exemplos e código em Python e R).

2. O que o grupo deve fazer

a. Escolher um par de testes (o grupo escolhe o par que quiser entre os abaixo)

Par	Testes	Exemplo de cenário
P1	t de Welch × Mann-Whitney	Tempo até o merge de PRs, com e sem bot de revisão
P2	t pareado × Wilcoxon pareado	Tempo de build antes e depois de ativar o cache
P3	ANOVA × Kruskal-Wallis	Tempo de revisão de PRs pequenos, médios e grandes
P4	Z para proporção × binomial exato	Taxa de builds com falha frente a uma meta de 5%
P5	Pearson × Spearman	Tamanho do módulo (LOC) × nº de defeitos

b Coletar uma amostra pequena de dados reais (cerca de 30 observações por grupo comparado)

Par	Coleta sugerida
P1	Tempo até o merge de PRs de um repositório público, com e sem bot de revisão (anotado da página do GitHub ou de um dataset pronto)
P2	Tempo de build ou dos testes de um projeto open-source, rodado ~15 vezes na própria máquina, com e sem cache (ou outra otimização)
P3	Tempo de revisão de PRs pequenos, médios e grandes de um repositório público
P4	Execuções de CI com falha na aba *Actions* de um repositório público
P5	Dataset público de defeitos por módulo (ex.: NASA MDP / PROMISE)

Registre de onde vieram os dados e como foram coletados. Não é preciso construir um pipeline: uma planilha ou um CSV bastam.

c Criar o cenário, com:

- a pergunta, em uma frase;
- as hipóteses H_0 e H_1;
- como os dados da simulação serão gerados: a distribuição de cada grupo e seus parâmetros, **escolhidos a partir dos dados reais** (ex.: “o tempo de merge real é assimétrico, com mediana de 10 h; usamos uma lognormal com essa mediana”);

- **antes de simular**, qual dos dois testes o grupo espera que se saia melhor, e por quê.

d Simular e comparar os testes, respondendo a três perguntas

Q1 Quando não há efeito, com que frequência cada teste “encontra” um efeito? (erro tipo I)
Gere 10.000 conjuntos de dados com H_0 verdadeira, aplique os dois testes e conte a proporção de p-valores < 0,05. O esperado é algo próximo de 5%.

Q2 Quando há efeito, com que frequência cada teste o detecta? (poder)
Repita a simulação com efeitos de tamanhos crescentes (no mínimo 5 valores, começando em zero) e conte a proporção de rejeições.

Q3 O que muda quando os dados não “se comportam bem”?
Repita Q1 e Q2 em pelo menos uma situação que viole os pressupostos do teste paramétrico, como dados muito assimétricos, *outliers* ou amostras pequenas.

e Visualizar: produza estes quatro gráficos

Gráfico	O que mostra
G1	Os dados reais ao lado dos dados simulados: histograma de cada grupo
G2	A distribuição da estatística do teste quando H_0 é verdadeira, com a região de rejeição sombreada e o p-valor de um exemplo marcado como área
G3	Erro tipo I dos dois testes em cada situação simulada, com uma linha em 5% (Q1 e Q3)
G4	Curvas de poder dos dois testes no mesmo gráfico: proporção de rejeições × tamanho do efeito (Q2 e Q3)

Em todos os gráficos: título, eixos com nome e unidade, legenda, e a mesma cor para cada teste.

3. Sprints

Lab04S01 7 pontos

Dados reais coletados (item b) + cenário (item c) + código que gera os dados simulados + os dois testes aplicados a **um** conjunto de dados simulado, com a interpretação do resultado + gráficos **G1** e **G2**.

Lab04S02 7 pontos

Simulações das perguntas Q1, Q2 e Q3 + gráficos **G3** e **G4**.

Entrega Final 6 pontos

O **dashboard** completo (3 pontos, seção 4) e a **apresentação oral** (3 pontos, seção 5).

Os gráficos das sprints já devem ser construídos dentro do dashboard: na S01 ele já mostra o G1 e o G2; na S02, o G3 e o G4.

4. Entrega final: o dashboard

A entrega final é **apenas o dashboard**, sem relatório em documento. Por isso, o dashboard precisa se explicar sozinho: **cada gráfico vem acompanhado de um texto curto** (2 a 4 frases) que diz o que o gráfico mostra e o que o grupo conclui dele.

O dashboard deve ter as seções abaixo, nesta ordem:

Seção	Gráfico	O que o texto deve dizer
1. Cenário	—	A pergunta, H_0 e H_1, de onde vieram os dados reais e quantas observações foram coletadas.
2. Os dados	G1	Como são os dados reais e os simulados (assimetria, outliers) e por que os parâmetros da simulação foram escolhidos assim.
3. Como os testes funcionam	G2	O que cada teste compara, onde fica a região de rejeição e o que significa o p-valor do exemplo.
4. Erro tipo I	G3	Se cada teste ficou perto de 5% em cada situação, e qual se desviou.
5. Poder	G4	Qual teste detecta melhor o efeito, e em que situações a vantagem muda de lado.

Seção	Gráfico	O que o texto deve dizer
6. Dados reais	tabela	Estatística, p-valor, tamanho do efeito e conclusão de cada teste nos dados coletados.
7. Conclusão	—	O que o grupo esperava antes de simular × o que encontrou, e a recomendação: qual teste usar no cenário, e quando a escolha mudaria.

- Pode ser feito em Streamlit, Dash, Plotly (página HTML), Quarto ou ferramenta equivalente, desde que gerado por código do repositório.
- Deve abrir com um único comando descrito no README, ou estar publicado (ex.: GitHub Pages, Streamlit Community Cloud).
- O link do dashboard e do repositório/GitHub Projects do grupo devem aparecer no topo do dashboard.

Link do repositório/GitHub Projects: `<preencher>`

5. Apresentação oral: 15 perguntas

Na aula de apresentação, o grupo responde, **usando o próprio dashboard**, às 15 perguntas abaixo. A apresentação dura até 7 minutos; as respostas devem ser curtas e diretas (cerca de 30 segundos cada). As perguntas são divididas entre os integrantes, e cada um responde a pelo menos 4. O professor pode pedir a qualquer integrante que responda a qualquer pergunta.

1	Qual é o cenário de vocês e o que H_0 e H_1 afirmam, em palavras simples?
2	O teste de vocês é unicaudal ou bicaudal? Por quê?
3	Como os dados reais foram coletados, e o que eles mostraram sobre a forma da distribuição?
4	Como os dados reais ajudaram a escolher os parâmetros da simulação?
5	O que cada um dos dois testes compara de fato (médias, postos, proporções...)?
6	No G2: o que é a distribuição da estatística sob H_0, e por que a região de rejeição fica onde fica?
7	O que significa o p-valor do exemplo mostrado no G2? E o que ele não significa?

8	No cenário de vocês, o que seria um erro tipo I e um erro tipo II? Qual dos dois seria mais grave?
9	No G3, algum teste se afastou de 5%? Ele ficou liberal ou conservador, e por quê?
10	No G4, qual teste tem mais poder? A diferença entre eles muda conforme o tamanho do efeito?
11	Que violação de pressuposto vocês simularam, e por que ela afeta mais um teste do que o outro?
12	Se vocês usassem $\alpha = 0{,}01$ em vez de 0,05, o que mudaria no G3 e no G4?
13	A simulação confirmou o que o grupo esperava antes de simular? Se não, o que explica a diferença?
14	Nos dados reais, os dois testes chegaram à mesma conclusão? O tamanho do efeito tem importância prática?
15	Qual teste vocês recomendam para o cenário, em que situação mudariam a recomendação, e qual é a principal limitação do estudo?

6. Para discutir: tamanho da amostra

As perguntas abaixo **não são exigências** de entrega. Servem para enriquecer o dashboard e a apresentação, para quem quiser ir além.

- Com o tamanho da amostra real que o grupo coletou, qual seria o poder de cada teste para detectar o efeito observado? (as curvas do G4 ajudam a estimar)
- Quantas observações seriam necessárias para chegar a 80% de poder? Isso seria viável de coletar no cenário real?
- Se o resultado nos dados reais não foi significativo, isso mostra que não há efeito, ou só que a amostra era pequena demais para detectá-lo?
- Com amostras muito grandes, até diferenças minúsculas ficam “significativas”. Nesse caso, o que importa mais: o p-valor ou o tamanho do efeito?
- O tamanho da amostra muda qual dos dois testes é o melhor? Os pressupostos pesam mais com amostras pequenas ou grandes?

7. Regras

- O código deve rodar do início ao fim com um único comando, descrito no README, usando **semente fixa** (ex.: `numpy.random.default_rng(42)`), para que os resultados possam ser reproduzidos.
- Podem ser usadas bibliotecas prontas (NumPy, SciPy, statsmodels, pandas, Matplotlib, Seaborn, Plotly).
- Em cada sprint, cada integrante deve ser Assignee de ao menos uma Issue com código commitado.

Prazo final: conforme cronograma da disciplina.

Valor total: 20 pontos · desconto de até 10% da nota da sprint por qualidade insuficiente do uso do GitHub Projects (WIP não respeitado, Issues sem Assignee, cartões desatualizados, ausência de evolução semanal).

Observação: a correção é feita a partir do GitHub Projects: commits sem referência ao número da Issue correspondente não serão considerados.

8. Dúvidas frequentes

Se vamos coletar dados reais, por que simular?

Porque, com dados reais, não se sabe a resposta certa: não dá para saber se o teste acertou ou errou. Na simulação, o grupo controla se existe efeito e de que tamanho, e por isso consegue medir o erro tipo I e o poder. Os dados reais servem para deixar a simulação realista e para a aplicação final.

Precisamos de muitos dados reais?

Não. Cerca de 30 observações por grupo comparado bastam. O foco do laboratório é a simulação.

Por que 10.000 repetições?

Para que a proporção estimada (ex.: 5%) tenha pouca variação. Com 10.000 repetições, a margem de erro fica em torno de ±0,4 ponto percentual.

O teste não paramétrico sempre ganha quando os dados não são normais?

Não necessariamente. Descobrir isso no cenário do grupo é justamente o objetivo do laboratório.